



PROPOSAL SKRIPSI

Judul :

Klasifikasi Citra Wilayah Perkotaan Menggunakan Convolutional
Neural Network

Disusun oleh :

ACHMAD NAJAMUDIN ANWAR NIM.
535190047

PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INFORMASI
UNIVERSITAS TARUMANAGARA
2026

LEMBAR PERSETUJUAN SIDANG PROPOSAL

Persetujuan

Nama : ACHMAD NAJAMUDIN ANWAR
NIM : 535190047
Program Studi : TEKNIK INFORMATIKA
Judul : Klasifikasi Citra Wilayah Perkotaan Menggunakan
Convolutional Neural Network

Proposal Skripsi ini disetujui untuk diuji

Jakarta, 26-Februari-2026

Pembimbing:
CHAIRISNI LUBIS, Dra., M.Kom.
NIK/NIP: 10393012



DAFTAR ISI

LEMBAR PERSETUJUAN SIDANG PROPOSAL.....	ii
DAFTAR ISI.....	iii
DAFTAR TABEL	v
DAFTAR GAMBAR	vi
DAFTAR LAMPIRAN	vii
BAB I PENDAHULUAN.....	1
1.1. Latar Belakang	1
1.2. Rumusan Rancangan.....	3
1.3. Komponen Rancangan.....	4
1.4. Spesifikasi Rancangan.....	5
1.5. Kegunaan Rancangan	6
1.6. Penelitian yang Relevan.....	6
BAB II LANDASAN TEORITIK	9
2.1. Sistem yang di rancang	9
2.2 Dasar Teori	10
2.2.1 Wilayah Perkotaan.....	11
2.2.3 Deep Learning	12
2.2.4 Convolutional Neural Network (CNN).....	13

2.2.5 EfficientNet.....	17
2.2.6 Evaluasi Kinerja Model	20
BAB III RANCANGAN DAN PEMBUATAN	22
3.1. Rancangan Sistem.....	22
3.1.1 Perencanaan Sistem	24
3.1.2 Analisis Sistem	26
3.1.3 Perancangan Sistem	27
DAFTAR PUSTAKA.....	29
LAMPIRAN 1	32
LAMPIRAN 2	33
LAMPIRAN 3	36
LAMPIRAN 4	38
LAMPIRAN 5	42

DAFTAR TABEL

DAFTAR GAMBAR

Gambar 2. 1 Diagram CNN	14
Gambar 2. 2 Implementasi Arsitektur CNN	15
Gambar 2. 3 Arsitektur EfficientNet-B2	18
Gambar L1. 1 Flowchart Alur Sistem.....	32
Gambar L2. 1 Searching Google Earth.....	33
Gambar L2. 2 Wilayah dan Kecamatan.....	34
Gambar L2. 3 Petakan satu Kelurahan	34
Gambar L2. 4 Dataset dibagi menjadi 3.....	35
Gambar L3. 1 Dataset Pemukiman Padat	36
Gambar L3. 2 Dataset Komersial	37
Gambar L3. 3 Dataset Ruang Terbuka Hijau	37
Gambar L5. 1 Halaman Utama.....	42
Gambar L5. 2 Halaman Pengujian	43
Gambar L5. 3 Halaman Pembuat	44

DAFTAR LAMPIRAN

BAB I

PENDAHULUAN

1.1. Latar Belakang

Perkembangan wilayah perkotaan yang semakin pesat menyebabkan perubahan tata ruang serta peningkatan kepadatan bangunan. Pertumbuhan jumlah penduduk dan kebutuhan hunian mendorong terbentuknya kawasan permukiman dengan jarak antarbangunan yang semakin rapat dan pola tata bangunan yang kurang teratur. Kondisi ini tidak hanya berdampak pada kualitas lingkungan, tetapi juga meningkatkan potensi risiko kebakaran. Beberapa penelitian menunjukkan bahwa wilayah dengan kepadatan bangunan tinggi dan akses yang terbatas cenderung memiliki tingkat kerentanan kebakaran yang lebih besar dibandingkan wilayah dengan ruang terbuka yang memadai, karena api lebih mudah menyebar pada area dengan jarak bangunan yang sempit dan minim pembatas alami[1] .

Untuk memahami karakteristik suatu wilayah, khususnya dari aspek kepadatan dan pola tata bangunan, citra satelit dan citra udara digital dapat dimanfaatkan sebagai sumber informasi spasial. Melalui citra tersebut dapat diamati susunan bangunan, pola jaringan jalan, distribusi vegetasi, serta perbedaan visual antara kawasan permukiman padat, kawasan komersial, dan

ruang terbuka hijau. Informasi visual ini berpotensi digunakan sebagai dasar identifikasi tipe wilayah dan tingkat kerapatannya. Namun, proses pengamatan dan klasifikasi citra secara manual memiliki keterbatasan, terutama ketika jumlah data yang dianalisis besar. Selain membutuhkan waktu yang lama, pendekatan manual juga berpotensi menimbulkan ketidakkonsistenan hasil interpretasi[2] .

Dalam beberapa tahun terakhir, metode Deep Learning khususnya Convolutional Neural Network (CNN) telah menunjukkan performa yang sangat baik dalam tugas klasifikasi citra. CNN mampu mengekstraksi fitur secara otomatis dari citra tanpa memerlukan proses ekstraksi fitur manual seperti pada metode tradisional. Hal ini menjadikan CNN lebih efektif dalam mengenali pola visual kompleks, termasuk pola kepadatan bangunan dan tata ruang wilayah perkotaan[2] .

Salah satu arsitektur CNN yang memiliki keseimbangan antara akurasi dan efisiensi komputasi adalah EfficientNet-B2. Arsitektur ini menggunakan teknik compound scaling untuk meningkatkan performa model tanpa meningkatkan kompleksitas secara signifikan. Oleh karena itu, penelitian ini menggunakan EfficientNet-B2 sebagai model utama dalam proses klasifikasi citra wilayah perkotaan[3] .

Penelitian ini merancang sistem klasifikasi citra wilayah perkotaan berbasis Convolutional Neural Network (CNN) menggunakan arsitektur EfficientNet-B2 untuk mengelompokkan wilayah ke dalam tiga kategori, yaitu pemukiman padat,

komersial, dan ruang terbuka hijau. Hasil klasifikasi ini tidak secara langsung memprediksi kejadian kebakaran, namun memberikan gambaran karakteristik kepadatan wilayah yang dapat digunakan sebagai dasar dalam analisis potensi risiko kebakaran di kawasan perkotaan[4] .

1.2. Rumusan Rancangan

1. Bagaimana merancang sistem klasifikasi citra wilayah perkotaan berbasis Deep Learning untuk mengidentifikasi karakteristik kepadatan wilayah ?
2. Bagaimana menerapkan pendekatan Convolutional Neural Network (CNN) dalam proses pengelompokan citra wilayah ke dalam kategori pemukiman padat, komersial, dan ruang terbuka hijau ?
3. Bagaimana tingkat kinerja sistem klasifikasi yang dirancang dalam mengidentifikasi tipe wilayah berdasarkan citra digital ?

1.3. Komponen Rancangan

Berikut ini merupakan komponen rancangan yang digunakan dalam sistem klasifikasi wilayah perkotaan :

1. Dataset Citra Wilayah Perkotaan

Dataset berupa citra digital wilayah perkotaan yang terdiri dari tiga kategori, yaitu pemukiman padat, komersial, dan ruang terbuka hijau. Dataset ini digunakan sebagai data latih dan data uji dalam proses pelatihan dan evaluasi model.

2. Model Deep Learning Berbasis CNN (EfficientNet-B2)

Model EfficientNet-B2 digunakan sebagai arsitektur utama dalam proses klasifikasi citra. Model ini berfungsi untuk mengenali pola visual wilayah berdasarkan karakteristik kepadatan bangunan dan tata ruang.

3. Rancangan Sistem Aplikasi Berbasis Web

Sistem dirancang dalam bentuk web application yang memungkinkan pengguna mengunggah citra wilayah dan memperoleh hasil klasifikasi secara langsung melalui browser.

1.4. Spesifikasi Rancangan

Berikut adalah spesifikasi rancangan sistem yang akan dibuat :

1. Modul Halaman Utama

Menampilkan informasi umum mengenai sistem klasifikasi wilayah perkotaan.

2. Modul Input Data

Digunakan untuk menerima citra wilayah perkotaan sebagai data masukan sistem.

3. Modul Proses Klasifikasi

Menjalankan analisis citra menggunakan metode Deep Learning berbasis EfficientNet-B2.

4. Modul Hasil

Menampilkan kategori wilayah berdasarkan hasil analisis sistem.

1.5. Kegunaan Rancangan

Pembuatan rancangan ini diharapkan dapat memberikan kontribusi baik secara akademik maupun praktis. Secara akademik, penelitian ini diharapkan dapat meningkatkan pemahaman mengenai penerapan metode Convolutional Neural Network (CNN) dalam klasifikasi citra wilayah perkotaan. Selain itu, penelitian ini dapat menjadi referensi dalam pengembangan sistem analisis wilayah berbasis citra digital menggunakan pendekatan Deep Learning. Secara praktis, hasil rancangan ini diharapkan dapat dimanfaatkan sebagai dasar dalam mengidentifikasi karakteristik kepadatan wilayah secara otomatis dan konsisten. Informasi yang dihasilkan dapat mendukung analisis potensi risiko kebakaran di kawasan perkotaan berdasarkan karakteristik visual wilayah.

1.6. Penelitian yang Relevan

Untuk memperkuat dasar penelitian ini, berikut merupakan beberapa penelitian terdahulu yang relevan :

1. Penelitian yang dilakukan oleh (Ridha Amini, Insyania Saragih dan Fatma Lestari) (2023) dalam jurnal berjudul “Kerentanan Kebakaran Daerah Perkotaan : Analisis Risiko dan Pemetaan di Jakarta Timur, Indonesia” membahas analisis tingkat risiko kebakaran di wilayah perkotaan berdasarkan faktor kepadatan bangunan, tata ruang, dan kondisi lingkungan fisik. Penelitian tersebut menggunakan pendekatan analisis spasial dan pemetaan untuk mengidentifikasi wilayah dengan tingkat kerentanan tinggi.

Hasil penelitian menunjukkan bahwa kawasan dengan kepadatan bangunan tinggi dan pola tata ruang yang tidak teratur memiliki risiko kebakaran yang lebih besar. Penelitian ini menyimpulkan bahwa karakteristik fisik wilayah berpengaruh signifikan terhadap tingkat kerentanan kebakaran di daerah perkotaan.

2. Penelitian yang dilakukan oleh (Ahmad Zuhdi, Muhamad Septa Utama Sp) (2024) dengan judul “Prediksi Wilayah Rawan Kebakaran Menggunakan Deep Learning” bertujuan untuk mengembangkan model berbasis Deep Learning dalam mengidentifikasi wilayah yang berpotensi mengalami kebakaran. Penelitian ini memanfaatkan metode pembelajaran mendalam untuk menganalisis data spasial dan melakukan proses pelatihan model guna menghasilkan prediksi tingkat kerawanan. Hasil penelitian menunjukkan bahwa pendekatan Deep Learning mampu meningkatkan akurasi dalam analisis wilayah rawan kebakaran dibandingkan metode konvensional.
3. Penelitian yang dilakukan oleh (Tian Tian, Chang Li, Jinkang Xu and Jiayi Ma) (2020) dalam jurnal berjudul “Urban Area Detection in Very High Resolution Remote Sensing Images Using Deep Convolutional Neural Network” membahas penerapan Convolutional Neural Network (CNN) dalam mendeteksi wilayah perkotaan pada citra resolusi tinggi. Penelitian tersebut menunjukkan bahwa CNN efektif dalam mengenali pola spasial seperti

kepadatan bangunan dan struktur tata ruang. Hasil penelitian menyatakan bahwa metode CNN memiliki tingkat akurasi yang tinggi dalam klasifikasi wilayah perkotaan.

4. Penelitian yang dilakukan oleh Rita Magdalena, Sofia Saidah, Nor Kumalasari Caecar Pratiwi, dan Akbar Trisnamulya Putra (2021) dalam jurnal berjudul *“Klasifikasi Tutupan Lahan Melalui Citra Satelit SPOT-6 dengan Metode Convolutional Neural Network (CNN)”* membahas penerapan metode Convolutional Neural Network (CNN) untuk mengklasifikasikan lima jenis tutupan lahan, yaitu hutan, bukit gundul, sawah, pemukiman, dan sungai menggunakan citra satelit SPOT-6 yang memiliki resolusi spasial tinggi. Penelitian ini menggunakan 350 data citra dengan pembagian 75% sebagai data latih dan 25% sebagai data uji, serta merancang arsitektur CNN yang terdiri dari tiga hidden convolutional layer, satu fully connected layer, fungsi aktivasi ReLU, max pooling, dan softmax untuk klasifikasi akhir. Hasil penelitian menunjukkan bahwa model CNN mampu mengekstraksi fitur spasial secara efektif tanpa memerlukan ekstraksi ciri manual, serta menghasilkan performansi yang sangat baik dengan akurasi sebesar 95,45%, loss 0,2457, serta rata-rata precision, recall, dan f1-score sebesar 0,92. Temuan ini membuktikan bahwa metode CNN sangat efektif dan optimal dalam melakukan klasifikasi tutupan lahan berbasis citra satelit resolusi tinggi.

BAB II

LANDASAN TEORITIK

2.1. Sistem yang di rancang

Sistem yang dikembangkan dalam penelitian ini bertujuan untuk mengklasifikasikan citra wilayah perkotaan ke dalam beberapa kategori berdasarkan tingkat kepadatan dan karakteristik tata ruang. Sistem ini dirancang dalam bentuk web application sehingga pengguna dapat mengunggah citra wilayah dan memperoleh hasil klasifikasi secara langsung melalui antarmuka berbasis browser. Dengan adanya sistem ini, proses identifikasi karakteristik wilayah dapat dilakukan secara otomatis dan konsisten menggunakan pendekatan Deep Learning.

Data yang digunakan dalam sistem berupa citra digital wilayah perkotaan yang terdiri dari beberapa kategori, seperti pemukiman padat, kawasan komersial, dan ruang terbuka hijau. Dataset ini dibagi menjadi data latih dan data uji untuk mendukung proses pembelajaran dan evaluasi model. Citra wilayah dipilih karena mengandung informasi visual yang merepresentasikan kepadatan bangunan, pola tata ruang, serta distribusi vegetasi yang berkaitan dengan karakteristik wilayah perkotaan.

Metode yang digunakan dalam penelitian ini adalah Convolutional Neural Network (CNN) dengan arsitektur EfficientNet-B2 sebagai model utama klasifikasi.

EfficientNet-B2 dipilih karena memiliki keseimbangan antara akurasi dan efisiensi komputasi melalui teknik compound scaling. Model ini mampu mengekstraksi fitur visual secara otomatis dari citra wilayah tanpa perlu proses ekstraksi fitur manual.

Sebelum dilakukan proses klasifikasi, citra yang diunggah akan melalui tahap pengolahan awal agar sesuai dengan kebutuhan model. Setelah proses tersebut, citra diproses oleh model EfficientNet-B2 untuk menghasilkan prediksi kategori wilayah. Proses pelatihan dilakukan menggunakan data latih, sedangkan evaluasi model dilakukan menggunakan data uji untuk mengukur tingkat performa sistem.

Setelah sistem dijalankan, pengguna dapat mengunggah citra wilayah melalui halaman utama aplikasi. Sistem kemudian memproses citra tersebut dan menampilkan hasil klasifikasi berupa kategori wilayah yang teridentifikasi. Hasil ini dapat digunakan sebagai gambaran karakteristik kepadatan wilayah yang berpotensi berkaitan dengan tingkat risiko kebakaran di daerah perkotaan.

Dengan alur tersebut, seluruh proses mulai dari pengolahan citra, pelatihan model EfficientNet-B2, hingga penyajian hasil klasifikasi dalam bentuk web application saling terintegrasi dalam satu sistem yang utuh.

2.2 Dasar Teori

Sebelum memasuki tahap implementasi sistem klasifikasi citra wilayah perkotaan, diperlukan pemahaman yang komprehensif terhadap teori-teori yang mendasarinya. Landasan teori ini membahas konsep wilayah perkotaan, citra satelit sebagai sumber data, teknologi deep learning, arsitektur Convolutional

Neural Network (CNN), EfficientNet sebagai model yang digunakan, serta metode evaluasi kinerja model. Pemahaman terhadap teori-teori tersebut menjadi dasar dalam perancangan sistem agar proses klasifikasi citra dapat dilakukan secara sistematis, rasional, dan ilmiah.

2.2.1 Wilayah Perkotaan

Wilayah perkotaan merupakan kawasan yang ditandai dengan tingkat kepadatan penduduk yang tinggi, dominasi aktivitas ekonomi non-pertanian, serta struktur tata ruang yang kompleks. Pertumbuhan wilayah perkotaan umumnya dipengaruhi oleh urbanisasi, perkembangan industri, serta peningkatan kebutuhan hunian dan fasilitas publik. Kondisi ini menyebabkan perubahan pola penggunaan lahan dan peningkatan kepadatan bangunan[2] .

Karakteristik wilayah perkotaan dapat diidentifikasi melalui pola visual seperti jarak antarbangunan, ukuran dan bentuk atap, kepadatan struktur terbangun, serta distribusi vegetasi. Kawasan permukiman padat umumnya memiliki jarak bangunan yang sempit dan pola yang tidak teratur. Kawasan komersial biasanya memiliki bangunan yang lebih besar dan terstruktur dengan akses jalan utama yang jelas. Sementara itu, ruang terbuka hijau didominasi oleh vegetasi dan memiliki kepadatan bangunan yang rendah[3] .

Identifikasi karakteristik wilayah perkotaan menjadi penting karena kepadatan bangunan yang tinggi sering kali berkaitan dengan peningkatan risiko

kebakaran. Bangunan yang berdekatan memungkinkan api menyebar dengan cepat, terutama pada wilayah dengan akses jalan yang terbatas. Oleh karena itu, klasifikasi wilayah berdasarkan karakteristik kepadatan dapat memberikan gambaran awal mengenai potensi kerentanan suatu kawasan[1] .

2.2.3 Deep Learning

Deep Learning merupakan bagian dari machine learning yang memanfaatkan jaringan saraf tiruan berlapis (multi-layer neural networks) untuk mempelajari representasi data secara otomatis. Pendekatan ini memungkinkan model untuk mengekstraksi fitur penting langsung dari data mentah tanpa memerlukan proses ekstraksi fitur secara manual sebagaimana pada metode konvensional. Melalui proses pembelajaran bertingkat, model deep learning mampu membentuk representasi fitur dari tingkat rendah seperti tepi dan tekstur hingga representasi yang lebih kompleks secara bertahap berdasarkan data pelatihan.

Dalam bidang penginderaan jauh, deep learning telah menunjukkan performa yang sangat baik dalam klasifikasi citra satelit karena kemampuannya mengenali pola visual yang kompleks dan variasi spasial pada citra. Berbeda dengan pendekatan tradisional yang bergantung pada perancangan fitur secara manual, deep learning secara otomatis mengoptimalkan parameter jaringan

untuk meningkatkan akurasi klasifikasi. Oleh karena itu, metode ini banyak diterapkan dalam tugas klasifikasi citra, deteksi objek, segmentasi, serta berbagai aplikasi pemetaan dan analisis wilayah berbasis citra satelit.

Pada klasifikasi citra wilayah perkotaan, deep learning memungkinkan sistem untuk mengidentifikasi karakteristik visual seperti kepadatan bangunan, distribusi vegetasi, dan pola tata ruang secara lebih konsisten dan objektif. Kemampuan tersebut menjadikan deep learning sebagai pendekatan yang efektif dalam menganalisis citra wilayah dengan kompleksitas tinggi[5] .


2.2.4 Convolutional Neural Network (CNN)

Convolutional Neural Network (CNN) merupakan arsitektur deep learning yang dirancang khusus untuk pengolahan citra. CNN bekerja dengan cara mengekstraksi fitur melalui operasi konvolusi menggunakan filter atau kernel, sehingga mampu mengenali pola visual secara bertingkat.

Secara umum, CNN terdiri dari beberapa komponen utama, yaitu convolution layer, pooling layer, dan fully connected layer[6] .

Arsitektur dasar CNN dapat digambarkan sebagai rangkaian lapisan yang tersusun secara berurutan mulai dari input layer, convolution layer, pooling layer, hingga fully connected layer dan output layer. Setiap lapisan memiliki fungsi yang berbeda namun saling terintegrasi dalam proses klasifikasi citra. Gambar 1 ini


menunjukkan struktur umum CNN yang menggambarkan alur pemrosesan citra dari tahap ekstraksi fitur hingga tahap klasifikasi akhir[7] .



Gambar 2. 1 Diagram CNN

Pada tahap awal, citra input diproses melalui convolution layer untuk mengekstraksi fitur seperti tepi, tekstur, dan pola visual lainnya. Selanjutnya, pooling layer digunakan untuk mengurangi dimensi feature map sehingga kompleksitas komputasi menjadi lebih efisien. Hasil dari beberapa lapisan konvolusi dan pooling kemudian diubah menjadi vektor satu dimensi melalui proses flatten sebelum diteruskan ke fully connected layer untuk proses klasifikasi. Output akhir biasanya menggunakan fungsi aktivasi Softmax untuk menentukan probabilitas setiap kelas[7] .

Untuk memberikan gambaran yang lebih rinci mengenai proses klasifikasi pada CNN, memperlihatkan contoh arsitektur CNN secara lebih spesifik yang mencakup jumlah filter, ukuran kernel, proses flatten, serta lapisan fully connected hingga output layer. Pada gambar tersebut terlihat bahwa citra input berukuran tertentu diproses melalui beberapa convolution layer dengan jumlah filter tertentu, kemudian melalui pooling layer untuk mengurangi dimensi feature map[8] .



Gambar 2. 2 Implementasi Arsitektur CNN

Setelah proses ekstraksi fitur selesai, feature map diubah menjadi vektor satu dimensi melalui proses flatten dan diteruskan ke hidden layer yang terdiri dari sejumlah neuron. Setiap neuron pada lapisan ini terhubung secara penuh (fully connected) dan menggunakan fungsi aktivasi seperti ReLU. Pada tahap akhir, output layer menggunakan fungsi Softmax untuk menghasilkan probabilitas setiap kelas yang akan diklasifikasikan[8] .

a. Convolution Layer

Convolution layer berfungsi untuk mengekstraksi fitur dari citra input. Operasi konvolusi dilakukan dengan menggeser kernel pada citra dan menghitung hasil perkalian antara nilai piksel dan bobot kernel[9] .

Secara matematis, operasi konvolusi dapat dinyatakan sebagai :

$$S(i,j) = (I * K)(i,j)$$

Keterangan :

$S(i,j)$ = nilai hasil konvolusi

I = citra input

K = kernel atau filter

Melalui proses ini, CNN dapat mendeteksi fitur sederhana seperti tepi dan tekstur pada lapisan awal, kemudian membentuk representasi fitur yang lebih kompleks pada lapisan berikutnya[9] .

b. Pooling Layer

Pooling layer berfungsi untuk mengurangi dimensi feature map sehingga kompleksitas komputasi menjadi lebih rendah. Salah satu metode yang umum digunakan adalah max pooling, yaitu mengambil nilai maksimum pada setiap area tertentu. Pooling membantu model menjadi lebih robust terhadap pergeseran posisi objek dan mengurangi risiko overfitting[10] .

c. Fully Connected Layer

Fully connected layer merupakan lapisan akhir dalam CNN yang digunakan untuk melakukan klasifikasi. Pada tahap ini, seluruh neuron terhubung dengan neuron pada lapisan sebelumnya untuk menghasilkan output akhir berupa prediksi kelas[10] .

d. Fungsi Aktivasi

Fungsi aktivasi digunakan untuk memperkenalkan non-linearitas pada model. Salah satu fungsi aktivasi yang umum digunakan adalah ReLU (Rectified Linear Unit)[10] :

$$f(x) = \max(0, x)$$

Untuk klasifikasi multi-kelas, digunakan fungsi Softmax :

$$P(y_i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}}$$

Softmax merupakan fungsi aktivasi yang digunakan pada lapisan akhir untuk permasalahan klasifikasi multi-kelas. Fungsi ini mengubah output jaringan menjadi probabilitas pada setiap kelas, sehingga Softmax dapat digunakan untuk menentukan probabilitas pada semua kelas dan memilih kelas dengan nilai probabilitas tertinggi sebagai hasil prediksi[10].

2.2.5 EfficientNet

EfficientNet merupakan pengembangan arsitektur CNN yang dirancang untuk meningkatkan akurasi dengan efisiensi parameter yang lebih baik. Arsitektur

ini dirancang untuk mengatasi keterbatasan metode scaling konvensional yang hanya meningkatkan satu dimensi jaringan, seperti kedalaman atau lebar jaringan saja[9] .



Gambar 2. 3 Arsitektur EfficientNet-B2

Pada implementasi model menggunakan arsitektur EfficientNetB2, terdapat 7 tahap yang terdiri dari beberapa lapisan untuk mempelajari setiap fitur atau pola dari data pelatihan. Setelah melalui ketujuh tahapan, terdapat lapisan tambahan seperti average pooling, flatten, dan fully connected layer sebagai tahap klasifikasi dari hasil pelatihan model[9] .

Compound Scaling pada EfficientNet

Compound scaling merupakan metode scaling yang meningkatkan dimensi jaringan secara proporsional pada tiga aspek utama, yaitu :

- a. Depth (kedalaman jaringan)

Depth mengacu pada jumlah layer dalam jaringan neural network. Semakin dalam jaringan, semakin kompleks fitur yang dapat dipelajari oleh model.

- b. Width (lebar jaringan)

Width mengacu pada jumlah filter pada setiap layer convolution. Semakin banyak filter, semakin banyak fitur yang dapat diekstraksi.

- c. Resolution (resolusi input)

Resolution mengacu pada ukuran citra input yang digunakan oleh model. Resolusi yang lebih tinggi memungkinkan model menangkap detail visual yang lebih baik.

Compound scaling menggunakan persamaan berikut :

- a. depth: $d = \alpha \phi$
- b. width: $w = \beta \phi$
- c. resolution: $r = \gamma \phi$

Dimana :

- a. ϕ = scaling coefficient
- b. α = konstanta scaling depth
- c. β = konstanta scaling width
- d. γ = konstanta scaling resolution

Dengan Batasan :

$$s.t. \alpha \cdot B^2 \cdot \gamma^2 \cdot = 2$$

Pendekatan ini memungkinkan model mencapai performa tinggi dengan jumlah parameter yang lebih optimal. Salah satu varian EfficientNet adalah EfficientNet-B2 yang memiliki keseimbangan antara kompleksitas model dan akurasi. EfficientNet-B2 cocok digunakan untuk klasifikasi citra resolusi menengah hingga tinggi dengan efisiensi komputasi yang baik[11] .

2.2.6 Evaluasi Kinerja Model

Evaluasi model dilakukan untuk mengukur performa sistem dalam mengklasifikasikan citra wilayah ke dalam kategori yang telah ditentukan[10] .

a. Confusion Matrix

Confusion matrix merupakan tabel yang menunjukkan perbandingan antara hasil prediksi dan label sebenarnya. Komponen utamanya meliputi[10] :

- a. True Positive (TP)
- b. True Negative (TN)
- c. False Positive (FP)
- d. False Negative (FN)

b. Accuracy

Accuracy menunjukkan persentase prediksi yang benar terhadap seluruh data[10] .

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

c. Precision

Precision menunjukkan ketepatan model dalam memprediksi kelas positif[10] .

$$Precision = \frac{TP}{TP + FP}$$

d. Recall

Recall menunjukkan kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya[10] .

$$Recall = \frac{TP}{TP + FN}$$

e. F1-Score

F1-Score merupakan rata-rata harmonis antara precision dan recall[10].

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

BAB III

RANCANGAN DAN PEMBUATAN

3.1. Rancangan Sistem

Perencanaan rancangan ini dilakukan untuk merancang alur kerja sistem klasifikasi citra wilayah perkotaan menggunakan metode Convolutional Neural Network dengan arsitektur EfficientNet-B2. Sistem ini dirancang untuk mampu mengklasifikasikan citra wilayah ke dalam beberapa kategori berdasarkan karakteristik visual yang terdapat pada citra tersebut.

Data yang digunakan dalam penelitian ini berupa dataset citra wilayah perkotaan yang diperoleh dari citra satelit. Dataset tersebut terdiri dari beberapa kategori wilayah, yaitu pemukiman padat, kawasan komersial, dan ruang terbuka hijau. Citra-citra tersebut digunakan sebagai dataset dalam proses pelatihan dan pengujian model klasifikasi.

Sebelum dilakukan proses pelatihan model, dataset citra terlebih dahulu melalui tahap pre-processing untuk memastikan bahwa data yang digunakan

memiliki format yang sesuai dengan kebutuhan model. Tahap pre-processing yang dilakukan meliputi perubahan ukuran citra menjadi 224×224 piksel agar sesuai dengan ukuran input pada arsitektur EfficientNet-B2.

Setelah tahap pre-processing selesai dilakukan, dataset kemudian dibagi menjadi beberapa bagian yaitu data latih dan data uji. Data latih digunakan untuk melatih model CNN agar dapat mempelajari pola visual dari setiap kategori wilayah, sedangkan data uji digunakan untuk mengevaluasi kinerja model dalam melakukan klasifikasi terhadap data yang belum pernah dilihat sebelumnya.

Proses pelatihan model dilakukan menggunakan arsitektur EfficientNet-B2 yang telah dilatih sebelumnya. Penggunaan model pre-trained bertujuan untuk memanfaatkan kemampuan awal model dalam mengenali pola visual sehingga proses pelatihan dapat menjadi lebih efisien. Setelah proses pelatihan selesai dilakukan, model akan menghasilkan bobot pembelajaran yang digunakan dalam proses klasifikasi citra.

Model yang telah dilatih kemudian diintegrasikan ke dalam aplikasi berbasis web sehingga pengguna dapat mengunggah citra wilayah dan memperoleh hasil klasifikasi secara langsung melalui sistem yang telah dirancang.

Selain itu, proses pengembangan sistem pada rancangan ini menggunakan pendekatan Software Development Life Cycle (SDLC) dengan model Waterfall. Model Waterfall dipilih karena memiliki tahapan pengembangan sistem yang

terstruktur dan dilakukan secara berurutan, mulai dari tahap perencanaan, analisis sistem, perancangan sistem, implementasi, hingga pengujian sistem[12] . Dengan menggunakan pendekatan ini, proses pengembangan sistem klasifikasi citra wilayah perkotaan dapat dilakukan secara sistematis sehingga memudahkan dalam perancangan, pengembangan, serta evaluasi sistem yang dihasilkan.

3.1.1 Perencanaan Sistem

Rancangan sistem pada penelitian ini diimplementasikan dalam bentuk aplikasi berbasis web yang memungkinkan pengguna untuk mengunggah citra wilayah perkotaan melalui antarmuka sistem. Citra yang dimasukkan kemudian diproses melalui beberapa tahapan, yaitu pengolahan awal citra dan proses klasifikasi menggunakan model Convolutional Neural Network (CNN) dengan arsitektur EfficientNet-B2. Setelah proses klasifikasi selesai dilakukan, sistem akan menampilkan hasil prediksi kategori wilayah berdasarkan citra yang dianalisis. Dengan adanya sistem ini diharapkan proses identifikasi karakteristik wilayah perkotaan dapat dilakukan secara lebih cepat dan konsisten. Adapun keseluruhan alur proses perencanaan sistem dapat dilihat pada **Lampiran 1**.

Data yang digunakan dalam penelitian ini berupa dataset citra wilayah perkotaan yang terdiri dari tiga kategori, yaitu pemukiman padat, kawasan komersial, dan ruang terbuka hijau. Dataset citra diperoleh dari citra satelit yang

diambil melalui platform Google Earth pada beberapa wilayah di Jakarta. Contoh citra yang digunakan dalam penelitian ini dapat dilihat pada **Lampiran 2** dan **Lampiran 3** sebagai representasi data yang digunakan dalam proses klasifikasi.

Sebelum digunakan dalam proses pelatihan model, dataset citra terlebih dahulu melalui tahap pre-processing untuk menyesuaikan data dengan kebutuhan model. Tahapan ini meliputi perubahan ukuran citra menjadi 224×224 piksel serta normalisasi data citra agar proses pembelajaran model dapat berjalan dengan lebih stabil. Setelah tahap pengolahan awal dilakukan, dataset kemudian dibagi menjadi data latih dan data uji untuk mendukung proses pelatihan serta evaluasi model.

Model yang digunakan dalam rancangan sistem ini adalah Convolutional Neural Network (CNN) dengan arsitektur EfficientNet-B2 sebagai model utama klasifikasi. Model EfficientNet-B2 yang digunakan merupakan model pre-trained, sehingga memiliki kemampuan awal dalam mengenali pola visual pada citra. Contoh proses perhitungan yang berkaitan dengan model yang digunakan dalam penelitian ini dapat dilihat pada **Lampiran 4**.

3.1.2 Analisis Sistem

Pada tahap analisis sistem dilakukan identifikasi terhadap kebutuhan perangkat keras dan perangkat lunak yang digunakan untuk mengembangkan sistem klasifikasi citra wilayah perkotaan.

1. Perangkat Keras (Hardware)

Perangkat keras yang digunakan untuk mendukung proses pengembangan dan pelatihan model antara lain :

- a. Processor Intel Core i7-4790
- b. RAM 8 GB
- c. Penyimpanan 112 GB SSD SSD 2.5" 120GB, 4 GB HDD
- d. GPU Intel(R) HD Graphics 4600
- e. Layar dengan resolusi minimal 1920×1080

2. Perangkat Lunak (Software)

Perangkat lunak yang digunakan dalam pengembangan sistem meliputi :

1. Windows 10 Pro
2. Python
3. TensorFlow atau PyTorch
4. Visual Studio Code
5. Figma contoh aplikasi berbasis web

Analisis kebutuhan perangkat keras dan perangkat lunak ini bertujuan untuk memastikan bahwa sistem yang dikembangkan dapat berjalan dengan baik selama proses pelatihan model maupun saat aplikasi digunakan oleh pengguna.

3.1.3 Perancangan Sistem

Pada tahap perancangan sistem dilakukan proses visualisasi untuk menggambarkan bagaimana aplikasi web yang dirancang akan digunakan oleh pengguna. Tahap ini bertujuan untuk memberikan gambaran mengenai struktur tampilan sistem serta alur interaksi antara pengguna dengan sistem klasifikasi citra wilayah perkotaan. Visualisasi ini disusun dalam bentuk rancangan tampilan antarmuka yang dapat mempermudah proses implementasi sistem pada tahap pengembangan selanjutnya.

3.1.3.1 Rancangan Tampilan Antarmuka

Rancangan tampilan antarmuka merupakan desain awal yang menggambarkan bagaimana pengguna akan berinteraksi dengan sistem klasifikasi citra wilayah perkotaan. Desain antarmuka ini disusun untuk memastikan bahwa sistem memiliki alur penggunaan yang jelas, mudah dipahami, serta mendukung fungsi utama sistem dalam melakukan klasifikasi citra wilayah.

Rancangan tampilan sistem pada penelitian ini dapat dilihat pada **LAMPIRAN 1**. Secara umum, tampilan sistem dibagi menjadi beberapa halaman utama sebagai berikut.

1. Halaman Utama

Halaman utama merupakan halaman awal yang akan ditampilkan ketika pengguna mengakses aplikasi web. Pada halaman ini ditampilkan informasi umum mengenai sistem yang dikembangkan, tujuan penelitian, serta penjelasan singkat mengenai fungsi sistem klasifikasi citra wilayah perkotaan. Halaman ini juga memberikan gambaran kepada pengguna mengenai cara penggunaan sistem secara umum.

2. Halaman Pengujian

Halaman pengujian merupakan bagian utama dari sistem yang digunakan untuk melakukan proses klasifikasi citra wilayah perkotaan. Pada halaman ini pengguna dapat mengunggah citra wilayah yang ingin dianalisis. Setelah citra dimasukkan ke dalam sistem, proses klasifikasi akan dilakukan menggunakan model EfficientNet-B2 yang telah dilatih sebelumnya. Hasil klasifikasi kemudian akan ditampilkan dalam bentuk kategori wilayah seperti pemukiman padat, kawasan komersial, atau ruang terbuka hijau.

3. Halaman Tentang Pembuat

Halaman tentang pembuat berisi informasi mengenai pengembang sistem yang merancang aplikasi ini. Pada halaman ini ditampilkan identitas pembuat sistem serta informasi singkat mengenai tujuan pengembangan sistem klasifikasi citra wilayah perkotaan dalam penelitian ini.

DAFTAR PUSTAKA

- [1] J. Teknika, A. Zuhdi, M. Septa, and U. Sp, "Teknika 18 (1): 127-138
Prediksi Wilayah Rawan Kebakaran Menggunakan Deep Learning,"
IJCCS, vol. x, No.x, pp. 1–5.
- [2] T. Tian, C. Li, J. Xu, and J. Ma, "Urban area detection in very high
resolution remote sensing images using deep convolutional neural
networks," *Sensors (Switzerland)*, vol. 18, no. 3, Mar. 2018, doi:
10.3390/s18030904.
- [3] R. M. #1, S. Saidah, K. Caecar, P. #3, A. Trisnamulya, and P. #4, "JEPIN
(Jurnal Edukasi dan Penelitian Informatika) Klasifikasi Tutupan Lahan
Melalui Citra Satelit SPOT-6 dengan Metode Convolutional Neural
Network (CNN)".
- [4] "Kerentanan kebakaran daerah perkotaan".
- [5] A. A. Adegun, S. Viriri, and J. R. Tapamo, "Review of deep learning
methods for remote sensing satellite images classification:
experimental survey and comparative analysis," *J. Big Data*, vol. 10,
no. 1, Dec. 2023, doi: 10.1186/s40537-023-00772-x.
- [6] L. S. Harahap and M. F. H. Kembaren, "Klasifikasi Objek
Menggunakan Convolutional Neural Network pada Citra Satelit,"
RIGGS: Journal of Artificial Intelligence and Digital Business, vol. 4,
no. 2, pp. 4663–4667, Jul. 2025, doi: 10.31004/riggs.v4i2.1306.


- [7] X. Jin, Y. Xu, F. Ye, Z. Zhou, Y. Wu, and B. Enkhtur, "Application of convolutional neural network in fusion and classification of multi-source remote sensing data."
- [8] A. Kholik, "KLASIFIKASI MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK (CNN) PADA TANGKAPAN LAYAR HALAMAN INSTAGRAM," *JDMSI*, vol. 2, no. 2, pp. 10–20, 2021.
- [9] H. K. Maulana, "PENERAPAN ARSITEKTUR CNN-EFFICIENTNETB2 DENGAN TRANSFER LEARNING PADA KLASIFIKASI GAMBAR TOKOH WAYANG KULIT," *Jurnal Informatika dan Teknik Elektro Terapan*, vol. 13, no. 1, Jan. 2025, doi: 10.23960/jitet.v13i1.5626.
- [10] M. Luthfi Bangun Permadi and R. Gumilang Sekolah Tinggi Teknologi Bandung, "PENERAPAN ALGORITMA CNN (CONVOLUTIONAL NEURAL NETWORK) UNTUK DETEKSI DAN KLASIFIKASI TARGET MILITER BERDASARKAN CITRA SATELIT."
- [11] M. Tan and Q. V. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," Sep. 2020, [Online]. Available: <http://arxiv.org/abs/1905.11946>
- [12] N. Hidayati and S. Sismadi, "Application of Waterfall Model In Development of Work Training Acceptance System," *INTENSIF: Jurnal Ilmiah Penelitian dan Penerapan Teknologi Sistem Informasi*,

vol. 4, no. 1, pp. 75–89, Feb. 2020, doi:

10.29407/intensif.v4i1.13575.

LAMPIRAN 1

FLOW ALUR KERJA SISTEM



Gambar L1. 1 Flowchart Alur Sistem


LAMPIRAN 2

TAHAPAN PENGAMBILAN DATASET

Pada lampiran ini menjelaskan bagaimana proses pengambilan data pada sistem yang akan di kembangkan. Penjelasan ini mencakup sumber dataset yang digunakan, teknik pengumpulan data, serta tahapan yang dilakukan untuk memperoleh data yang dibutuhkan dalam rancangan sistem ini. Lampiran ini disusun agar pembaca dapat memahami secara jelas cara pengumpulan data yang dilakukan, sehingga proses yang digunakan dalam rancangan ini menjadi lebih transparan dan efisien yang dapat dijadikan sebagai referensi bagi penelitian atau rancangan selanjutnya. Berikut merupakan tahapan pengambilan data dalam sistem ini


1. Data dalam rancangan ini diambil melalui google earth atau citra satelit

Langkah awal nya perwilayah, kecamatan dan kelurahan searching bisa dilihat pada **Gambar 5.**




Gambar L2. 1 Searching Google Earth

2. Setelah selesai searching akan muncul peta satu wilayah dan pilih satu kecamatan yang akan di cari bisa dilihat pada **Gambar 6**.



Gambar L2. 2 Wilayah dan Kecamatan

3. Setelah screenshot wilayah pilih kecamatan maka dipetakan di satu area kelurahan bisa dilihat pada **Gambar 7**.



Gambar L2. 3 Petakan satu Kelurahan


4. Setelah kemudian bikin folder yang mencakup 3 label yaitu : pemukiman padat, komersial dan ruang terbuka/hijau bisa dilihat pada **Gambar 8**.



Gambar L2. 4 Dataset dibagi menjadi 3

LAMPIRAN 3


DATASET YANG AKAN DIGUNAKAN



Gambar L3. 1 Dataset Pemukiman Padat



Gambar L3. 2 Dataset Komersial



Gambar L3. 3 Dataset Ruang Terbuka Hijau

LAMPIRAN 4

CONTOH PERHITUNGAN CNN

Untuk memahami cara kerja Convolutional Neural Network (CNN) dalam melakukan klasifikasi citra wilayah perkotaan, pada bagian ini ditunjukkan proses perhitungan operasi konvolusi secara matematis menggunakan matriks citra sederhana. Ilustrasi ini digunakan untuk menggambarkan bagaimana CNN mengekstraksi fitur dari citra sebelum diproses lebih lanjut oleh arsitektur CNN yang lebih kompleks seperti EfficientNet-B2.

Pada penelitian rancangan ini citra yang digunakan merupakan citra wilayah perkotaan yang diperoleh dari citra satelit dan terdiri dari beberapa kategori, yaitu pemukiman padat, kawasan komersial, dan ruang terbuka hijau. Untuk mempermudah penjelasan proses perhitungan, diasumsikan sebuah citra grayscale berukuran 4×4 piksel sebagai input awal, dengan nilai piksel sebagai berikut :

$$I = \begin{bmatrix} 1 & 2 & 3 & 4 \\ 5 & 6 & 7 & 8 \\ 9 & 10 & 11 & 12 \\ 13 & 14 & 15 & 16 \end{bmatrix}$$

Selanjutnya digunakan kernel (filter) berukuran 2×2 untuk melakukan proses konvolusi terhadap citra input. Kernel yang digunakan diasumsikan sebagai berikut :

$$K = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}$$

Proses konvolusi dilakukan dengan menggeser kernel pada citra input dan menghitung hasil perkalian antara nilai piksel citra dengan bobot kernel pada setiap area yang dilalui.

Secara matematis operasi konvolusi dapat dituliskan sebagai :

$$S(i,j) = (I * K)(i,j)$$

Keterangan :

$S(i,j)$ = nilai hasil konvolusi

I = citra input

K = kernel atau filter

Contoh Perhitungan pertama :

$$\begin{bmatrix} 1 & 2 \\ 5 & 6 \end{bmatrix} * \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix} = (1 \times 1) + (2 \times 0) + (5 \times 0) + (6 \times -1) = 1 - 6 = -5$$

Proses ini dilakukan pada seluruh area citra sehingga menghasilkan feature map sebagai berikut :

$$\begin{bmatrix} -5 & -5 & -5 \\ -5 & -5 & -5 \\ -5 & -5 & -5 \end{bmatrix}$$

Feature map ini mempresentasikan fitur tertentu yang berhasil di deteksi oleh kernel dari citra input . Setelah proses konvolusi, hasil feature map akan melalui fungsi aktivasi ReLu untuk memperkenalkan sifat non-linear pada model Fungsi ReLu di rumuskan sebagai :

$$ReLU(x) = \max(0, x)$$

Artinya nilai negatif akan diubah menjadi 0, sedangkan nilai positif tetap dipertahankan. Hasil konvolusi bernilai negative, maka setelah melewati ReLu diperoleh :

$$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

Fungsi aktivasi ini mempelajari pola yang lebih kompleks pada data citra Setelah proses aktivasi, feature map akan diproses menggunakan pooling layer untuk mengurangi dimensi data dan mempertahankan fitur penting. Salah satu metode yang umum digunakan adalah max pooling.

Menggunakan max pooling 2×2 , maka feature map sebelumnya akan diperoleh nilai maksimum dari setiap area pooling.


$$\begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

Pooling membantu mengurangi kompleksitas komputasi serta membuat model lebih tahan terhadap pergeseran posisi objek pada citra. Setelah proses


pooling, hasil feature map diubah menjadi bentuk vektor satu dimensi agar dapat diproses pada lapisan klasifikasi. Proses ini disebut flatten, untuk mengubah matriks dua dimensi menjadi vektor satu dimensi tanpa mengubah urutan data. Pada proses Klasifikasi menghasilkan vektor hasil flatten kemudian diproses oleh fully connected layer untuk menghasilkan prediksi kelas citra. Pada rancangan ini, kelas yang digunakan adalah : Pemukiman Padat, komersial dan ruang terbuka Hijau. Pada tahap akhir digunakan fungsi softmax untuk menghasilkan probabilitas setiap kelas sehingga sistem dapat menentukan kategori wilayah dengan probabilitas tertinggi dan softmax bisa untuk semua kelas.

LAMPIRAN 5


GAMBARAN RANCANGAN TAMPILAN ANTARMUKA



Gambar L5. 1 Halaman Utama



Gambar L5. 2 Halaman Pengujian



Gambar L5. 3 Halaman Pembuat